

评分细则-选手版

道通无人机巡检多模态大模型竞赛·第二阶段评分标准（选手版）

本文档为赛前说明会发放的选手参考材料，提供第二阶段（现场比赛）的评分标准、分值核算规则及公平性保障机制。赛方保留在赛事期间根据实际情况对评审执行细节进行合理调整的权利，调整不影响本文档所列的评分标准与核算公式。

一、总则

本评分标准适用于道通无人机巡检多模态大模型竞赛的第二阶段（现场比赛）。评分标准围绕道路巡检业务实际需求制定，大模型输出 L1 精细感知、L2 推理分析与 L3 决策建议；本阶段在第一阶段感知的基础上，重点考核模型在病害/事件的精细描述与成因推理、风险研判与处置决策等核心能力维度上的表现。

术语说明：本标准中「病害/事件」泛指所有评测目标，包括路面病害、路外病害及异常事件（抛洒物）。

关于原 Task2（违停场景）的说明：经赛方审慎评估，原 Task2（路面异常事件——违停）任务难度过高，且比赛前期（L1 阶段）对该场景的 L2、L3 输出结果说明存在歧义，导致第二阶段专家评分标准难以统一。为保障比赛专家打分顺利进行，该场景相关测试样本整体删除，不再评测其 L2、L3 分数，不计入最终总得分。剩余任务与场景已重新编号。

关于 Task1（抛洒物）成因推理自动满分的说明：经赛方审慎评估，高速公路抛洒物的成因在实际巡检场景中高度趋同，成因推理的区分度极低。为保障比赛公平性，赛方决定不对 Task1 的成因推理维度进行评审，该维度对所有参赛团队统一判定为满分（40 分）。

任务与场景范围

原编号	新编号	场景名称	所属任务
Scene0	Scene0	抛洒物	Task1：路面异常事件
Scene1	(已删除)	违停	—
Scene2	Scene1	裂缝	Task2：路面病害
Scene3	Scene2	坑洼	Task2：路面病害
Scene4	Scene3	积水	Task2：路面病害
Scene5	Scene4	护栏破损	Task2：路面病害
Scene6	Scene5	边坡破损	Task3：路外病害
Scene7	Scene6	排水沟积水	Task3：路外病害
Scene8	Scene7	排水沟破损	Task3：路外病害

评审基本原则

- 业务导向原则：**评分标准紧贴道路巡检与养护业务场景，强调输出内容的专业性、针对性、可执行性与实操价值。
- 合理表达原则：**本标准不要求唯一标准答案，不以固定措辞作为唯一判定依据；对同义表达、近义表达、合理业务表述，均视为有效。
- 逻辑一致原则：**L2 描述必须与 L1 结果一致，L3 决策必须与 L1 和 L2 一致，禁止脱节、跳步、矛盾性输出。

三档评分制（全局适用）

L2、L3 的所有评分要点均采用统一的三档评分制，每项评分要点均为 20 分。评分不以措辞华丽程度、篇幅长短或表述风格作为主要依据。

档位	分值	判定标准
达标	20 分	输出围绕当前样本的正确目标展开，覆盖该评分要点的大多数关键观察点，内容专业、合理，无明显错误
部分达标	10 分	输出方向基本正确，但仅覆盖部分关键观察点，或存在明显缺项、表述笼统、分析深度不足
未达标	0 分	输出缺失；或内容严重错误；或与当前场景事实、目标类型根本矛盾

L2 与 L3 独立评审

L2 阶段判零不自动触发 L3 阶段判零，L3 始终独立评审。

判零层级

本标准的判零规则按优先级从高到低分为三级：

层级	名称	触发效果
第一级	样本级判零	该样本的 L2、L3 整体计 0 分，不送入专家评审
第二级	阶段级判零	该阶段（L2 或 L3）整体计 0 分，跳过维度评分
第三级	维度级判零	该评分要点计 0 分（20 分归零）

样本级判零触发条件： 对每个测试样本，系统根据 L1 检测结果计算该样本的 F1 值。若样本 $F1 < 0.5$ ，则该样本的 L2、L3 分数直接判定为 0 分，不进入专家评审环节。

阶段级判零触发条件（L2 和 L3 各自独立判定，满足任一即触发）：

- Z1 输出为空：无任何有效文本输出，或仅含无意义占位符（如空字符串、null、「无」、「N/A」等）；
- Z2 目标类型根本错位：分析/决策的目标类型与 L1 识别结果完全不一致（如 L1 识别为抛洒物，L2 却在分析路面裂缝）；
- Z3 整体脱离业务：输出内容整体脱离道路巡检业务场景（如模型幻觉、与道路巡检完全无关的内容、大段重复乱码）；
- Z4 格式违规：输出不符合赛事指定格式，系统无法正常解析关键字段。

二、分值核算规则

提交与选取规则

现场封闭开发阶段，每支参赛团队最多可发起 3 次提交。最晚提交时间不得晚于 4 月 1 日 18:00，逾期提交将直接返回提交失败，不予受理。每次提交需满足 API 接口响应要求（参见第五节）。提交采用串行机制：每次提交后由赛方评测系统进行 L1 自动评测，评测完成后系统直接向选手反馈本次提交的 L1 得分，供团队作为模型优化的参照指标；选手须等待上一次提交的评测完成反馈后，方可发起下一次提交。

提交通道关闭后，赛方对每个团队的所有有效提交进行 L1 评分（系统自动 IoU 匹配），选出 L1 得分最高的一次提交作为该团队的最终提交，进入后续的 L2、L3 专家打分及可能的答辩环节（4 月 2 日）。

场景权重

本标准所有阶段满分均为 100 分。八个场景权重统一分配，每个场景权重系数均为 0.125，合计 1.000。

场景	Task	权重
Scene0 抛洒物	Task1	0.125
Scene1 裂缝	Task2	0.125
Scene2 坑洼	Task2	0.125
Scene3 积水	Task2	0.125
Scene4 护栏破损	Task2	0.125
Scene5 边坡破损	Task3	0.125
Scene6 排水沟积水	Task3	0.125
Scene7 排水沟破损	Task3	0.125
合计		1.000

第一阶段：L1 感知得分与晋级筛选

基于每个团队最终提交的 L1 评测结果（经系统自动 IoU 匹配），计算 $Score_{L1}$ 并排名，排名前 50% 的团队晋级，进入第二阶段 L2、L3 专家打分环节。

$$Score_{L1} = 100 \times \sum_{j=0}^7 0.125 \cdot F_{1,j}$$

其中 $F_{1,j}$ 为第 j 个场景的 F1 值（基于系统自动 IoU 匹配的 TP/FP/FN 计算）。

第二阶段：场景综合得分与答辩入围

晋级团队进入 L2、L3 专家打分环节。每个场景的综合得分按 L1（60%）+ L2（20%）+ L3（20%）加权计算：

$$\text{SceneScore}_j = 0.6 \cdot \text{Score}_{L1,j} + 0.2 \cdot \text{Score}_{L2,j} + 0.2 \cdot \text{Score}_{L3,j}$$

各场景综合得分按权重加权求和，作为第二阶段排名依据：

$$0.125 \cdot \sum_{j=0}^7 \text{SceneScore}_j$$

按上述加权求和结果排名，取前五名团队进入第三阶段答辩环节。

第三阶段：答辩与总得分

前五名团队依次进行 10 分钟答辩（前 5 分钟由团队代表介绍赛题解决方案，后 5 分钟由在场专家提问）。

Innovation Score 评分维度：

子维度	考核内容	三档评分
技术创新性	模型架构、训练策略、数据工程是否有创新点	0 / 15 / 30
方案完整性	从数据准备到模型部署的端到端方案是否完整、逻辑清晰	0 / 15 / 30
工程可落地性	方案是否具备真实业务部署可行性，资源消耗是否合理	0 / 20 / 40

每位评委的 Innovation Score = 技术创新性得分 + 方案完整性得分 + 工程可落地性得分，满分 100 分。

总得分计算：

$$\text{Final Score} = 0.125 \cdot \sum_{j=0}^7 \text{SceneScore}_j \cdot 0.8 + \text{Innovation Score} \cdot 0.2$$

根据总得分排名，确定前三名获奖团队。

三、L2 推理分析阶段评分维度（100 分）

L2 推理分析阶段考核模型对病害/事件目标的精细描述与成因推理两大能力，总分 100 分。所有分析内容需严格依托 L1 阶段识别的病害/事件目标展开。

精细特征描述（60 分，3 项评分要点）

#	评分要点	分值	考核内容
1	专业理解与场景描述	20 分	是否结合养护行业常识与当前场景，对检测对象作出专业理解；是否依据图像对道路空间结构（视角、路幅/车道等）作出合理表述
2	特征识别与属性判断	20 分	是否完整、准确描述病害/事件的细粒度视觉特征（形状、颜色、相对尺寸等）与类型归属（如横向/纵向/龟裂、塑料/碎石/车辆零部件等）
3	空间分布描述	20 分	是否完整、准确描述病害/事件的空间分布信息（所属车道/部位、数量、位置对应关系等）

成因推理（40 分，2 项评分要点）

Task1（抛洒物）的成因推理不做评审，该 40 分直接判定为满分。

#	评分要点	分值	考核内容
1	成因推测合理性	20 分	病害/事件成因推理是否具体、合理，有据可依、符合养护行业常识
2	场景化多维度分析	20 分	是否结合季节、天气、地理环境、道路养护周期、交通荷载、材料老化等多维度因素综合研判

四、L3 决策阶段评分维度（100 分）

L3 决策阶段考核模型基于 L1 感知与 L2 分析结果，进行风险研判并制定科学、可操作、针对性处置方案的能力，总分 100 分。

风险研判与处置优先级判定（40 分，2 项评分要点）

#	评分要点	分值	考核内容
1	风险等级与核心危害判定	20 分	是否明确标注风险等级（极高/高/中/低），且与病害/事件实际特征相符；是否说明核心危害并预判风险扩散趋势

2	处置优先级与时效性	20 分	是否明确标注处置优先级且与风险等级一一对应；是否说明处置时限与作业窗口
---	-----------	------	-------------------------------------

风险等级与处置优先级映射关系（固定）：

风险等级	处置优先级
极高风险	立即处置
高风险	尽快处置
中风险	常规巡检处置
低风险	定期观测

针对性处置措施（60 分，3 项评分要点）

#	评分要点	分值	考核内容
1	处置方案完整性	20 分	处置措施是否包含现场即时处置、后续跟进处置两大核心环节
2	差异化与针对性	20 分	是否按病害/事件材质、特征、程度制定差异化处置方式；是否建议必要工具与资源
3	执行标准与联动协调	20 分	是否明确处置执行主体、操作标准与验收要求；高危场景是否提及跨部门联动

五、赛题补充说明

模型使用限制

禁止购买模型以及调用商用大模型 API 接口。允许基于开源模型进行微调与二次开发。评测系统采用内网环境测试，确保模型完全本地运行。

API 接口响应要求

场景类型	单样本响应时限	超时后果
所有评测场景（Task1/2/3）	≤ 60 秒	该样本 L1、L2、L3 全部计 0 分

全部评测样本总耗时不得超过 6 小时。

六、公平性保障机制

赛方在评分流程设计中采取以下措施保障比赛公平性：

保障机制	说明
L1 系统自动评测	L1 阶段的 TP/FP/FN 判定与 F1 计算完全由系统自动完成，无人工干预

统一样本集	所有晋级团队在完全一致的测试样本集下进行 L2/L3 分数计算
全场景覆盖	评审覆盖全部 8 个场景，确保各场景被等强度评估
双评委独立评审	每个有效预测结果由两位不同的道路养护专家独立打分，最终取平均值
答辩去极值	答辩 Innovation Score 分组计算：养护专家组和算法专家组各自去掉最高最低分后取平均，再按权重合并
L2/L3 独立评审	L2 判零不自动触发 L3 判零，两阶段始终独立评分
统一评分标准	所有评分要点均采用三档评分制（20/10/0），降低专家主观差异

七、附则

- 本标准未尽事宜，参照道路病害巡检行业通用规范及赛事官方技术方案补充执行。
- 赛事组委会可根据实际评审需求对评审执行细节进行合理调整，本文档所列评分标准与核算公式保持不变。